

Agenda

1. Problema e pergunta do modelo
2. Dados: fontes, volume e rótulo
3. Descritores: carga, hidrofobicidade e μH
4. PMI: fórmula e origem (in silico)
5. Features: baseline e multimodal (ESM-2)
6. Modelagem: RF, LOPO e calibração
7. Resultados (baseline e multimodal)
8. Uso: dashboard, API e deploy
9. Limitações e próximos passos

Problema

Contexto

Peptídeos de *Tityus stigmurus* (Stigmurin e análogos) interagem com membranas diversas (Gram+/Gram−, fungo, célula mamífera). Testar todos os pares in vitro é caro.

Pergunta operacional

- ▶ Dado peptídeo + membrana-alvo,
- ▶ qual a chance de **alta atividade**?
- ▶ Rótulo: $MIC \leq 3,4 \mu M$

Papel do PoC

Priorizar candidatos.
Não substitui MIC,
hemólise nem clínica.

De onde veio o desenho

Pipeline InovAI (Nível 1)

Baselines: RF, XGBoost, SVM, logreg.

Com poucos dados: classificador +
encoder congelado; PMI + SHAP.

PoC implementado

RF (baseline e multimodal).

ESM-2 t6_8M como embedding.


SHAP TreeExplainer no dashboard.

Proposta CNPq (horizonte)

Deep learning multimodal
(MLP / Transformers).

Meta de médio/longo prazo;
não é o modelo em produção no Cloud.

Dados — fontes



- ▶ Bancada **sobrescreve** literatura no mesmo par (`import_bench_mic.py`).
- ▶ Distribuição atual dos MICs: **78** bancada + **12** literature = **90**.
- ▶ Alvos com MIC: **18** membranas distintas.

Dados — volume e rótulo

Conjunto de treino

- ▶ **90** pares com MIC
- ▶ **10** peptídeos distintos
- ▶ Taxa positiva: **44,4%**

Rótulo binário

$$y = \begin{cases} 1 & \text{se } \text{MIC} \leq 3,4 \mu\text{M} \\ 0 & \text{caso contrário} \end{cases}$$

Limiar operacional do projeto
(valores ativos em Parente 2022).

Mediana dos MICs $\approx 4,7 \mu\text{M}$ — o corte $3,4 \mu\text{M}$ *não* é a mediana.

Descritores do peptídeo — da sequência

Carga líquida q_p (pH ~ 7)

Soma dos resíduos ionizáveis:

K, R = +1; H = +0,1;

D, E = -1; demais = 0.

Se houver carga anotada (`net_charge`), ela prevalece.

Hidrofobicidade h_p

Média Kyte–Doolittle por resíduo:

$$h_p = \frac{1}{L} \sum_i H(AA_i)$$

L = 3,8; K = -3,9.

Momento hidrofóbico μH_p

Eisenberg (hélice α , ângulo 100°):

$$\mu H = \frac{1}{L} \sqrt{\left(\sum H_i \cos i\theta\right)^2 + \left(\sum H_i \sin i\theta\right)^2}$$

Anfifilicidade: faces hidrofóbica / hidrofílica.

Importante

Tudo é **in silico** a partir da sequência.

Não é medido na bancada.

Código: `pepmem/peptide_utils.py`, `pepmem/pmi.py`

Membrana e PMI — como se obtém

Descritores da membrana

Tabela de alvos (membrane_targets):

- ▶ q_m (carga superficial)
- ▶ Fração aniônica, LPS, peptidoglicano
- ▶ Colesterol, ergosterol, envelope viral

Tipologia OPM + regras do projeto
(Gram+/Gram−/fungo/célula normal. . .).

h_m na inferência: proxy fixo 0,5.

PMI (não é ensaio)

$$\text{PMI} = \alpha q_p |q_m| + \beta h_p h_m + \gamma \mu H_p - \delta \text{col}_m$$

$\alpha=1; \beta=0,5; \gamma=0,3; \delta=0,4$

(pesos fixos de projeto, não aprendidos).

Bancada vs PMI

Bancada / literatura: MIC (rótulo).

PMI: índice calculado do par.

$$\text{PMI}_{\text{sel}} = \text{PMI}_{\text{alvo}} - \text{PMI}_{\text{normal}}$$

(só no ranking, não no RF).

Features — baseline (11) e multimodal

Baseline — 11 clássicas

Peptídeo: q , h , μH

Membrana: carga, aniônica, colesterol,
LPS, peptidoglicano, ergosterol, viral
+ **PMI**

Deploy Cloud (sem PyTorch).

Multimodal — + ESM-2

facebook/esm2_t6_8M_UR50D

mean-pool $\sim 320d \Rightarrow \approx 331$ features

HF Space / local com torch.

Por que t6 8M?

Só precisa da sequência;
cabe em CPU / Space;
complementa o PMI sem
estrutura 3D.


SHAP (baseline)

Top: q_p , **PMI**, q_m .

Multimodal: ESM agregado

domina; PMI ≈ 0 no global.

Pipeline de modelagem



- ▶ Pipeline: `StandardScaler` → `RandomForestClassifier`
- ▶ Baseline: 200 árvores; multimodal: 300 árvores, `max_depth=6`
- ▶ `class_weight='balanced'`

Validação: LOO vs LOPO

LOO (por amostra)

Tira **1 par** por vez.

O mesmo peptídeo pode ficar no treino (outro alvo).

AUC mais otimista

(vazamento por homologia).

LOPO (por peptídeo)

Tira **todo** o peptídeo.

Generalização para sequência nunca vista.

Métrica principal +

probs OOF para calibração.

Família Stigmurin: análogos ~94% idênticos $\Rightarrow$ LOPO é essencial.



Calibração isotônica

- ▶ RF ordena bem, mas `predict_proba` é **voto do ensemble**, não frequência real.
- ▶ Com ~ 90 MICs, probs brutas tendem a polarizar (0/1).
- ▶ **IsotonicRegression** nas probs OOF do LOPO $\rightarrow p_{\text{calibrada}}$.
- ▶ Preserva a ordem dos candidatos; alinha % do dashboard ao LOPO.

Inferência

$$p_{\text{bruta}} = \text{RF.predict_proba} \rightarrow p_{\text{calibrada}} = \text{calibrator.predict}([p_{\text{bruta}}])$$

Calibração isotônica — interpretação visual



A curva ajusta a escala de probabilidade, mas preserva a ordenação dos candidatos.

PepMem-AI

Resultados — Baseline RF

LOPO AUC

0,88

métrica principal

LOO AUC

0,88

referência

Acurácia LOPO

0,74

40 positivos / 90

- ▶ Modelo: 11 features clássicas + PMI
- ▶ Deploy: Streamlit Cloud (sem PyTorch)
- ▶ Calibração: isotônica sobre OOF LOPO
- ▶ LOO acc. 0,83 · F1+ (LOPO) 0,73

Resultados — Multimodal RF + ESM-2

LOPO AUC

0,81

métrica principal

LOO AUC

0,85

referência

Acurácia LOPO

0,69

40 positivos / 90

- ▶ Embedding captura similaridade de sequência; no LOPO generaliza um pouco pior nesta família pequena
- ▶ Deploy: Hugging Face Space / local com `requirements-space.txt`


Comparação exploratória — RF, SVM e XGBoost

Modelo	AUC LOPO	Acc. LOPO	F1+	Recall+	Brier
RF baseline	0,878	0,744	0,729	0,775	0,140
XGBoost	0,847	0,756	0,738	0,775	0,173
SVM RBF	0,763	0,767	0,774	0,900	0,180

Decisão atual

Manter o RF como modelo principal: lidera a AUC LOPO. XGBoost é o candidato para ajuste aninhado futuro.

Distribuição das 11 features de entrada



AUC LOPO por peptídeo (baseline)

ID	AUC	ID	AUC
P11	0,90	P15	0,83
P12	0,95	P16	0,95
P13	0,88	P17	0,80
P14	0,88	P18	0,67

- ▶ P05 e P10: AUC por peptídeo indefinida (uma só classe no fold)
- ▶ Variabilidade entre análogos — amostra ainda limitada

Explicabilidade e produto

SHAP

TreeExplainer no RF.
Beeswarm global + local.
Dims ESM agregadas no gráfico.

Onde roda

Cloud: baseline leve
Space HF: multimodal
API FastAPI (opcional)

Dashboard

Predição única / lote FASTA
Ranking multi-alvo
Relatórios MD/DOCX/PDF

Docs

docs/TREINO.md
docs/INTERPRETACAO_RESULTADOS.md

Limitações

- ▶ Poucos peptídeos distintos (~ 10 com MIC) — LOPO ajuda, mas amostra é pequena
- ▶ Limiar $3,4 \mu\text{M}$ é escolha de projeto, não padrão CLSI
- ▶ Hemólise existe nos pares, mas o RF classifica **atividade MIC**, não toxicidade direta
- ▶ Multimodal ainda é RF+ESM, não o encoder multimodal completo da proposta CNPq
- ▶ Predição **prioriza** ensaio; não substitui bancada

Mensagens-chave

1. **Dados:** 90 MICs (bancada + literatura), rótulo $\text{MIC} \leq 3,4 \mu\text{M}$
2. **Descritores:** q , h , μH da sequência; membrana tipificada; PMI **calculado** (não ensaiado)
3. **Modelo:** Random Forest (Nível 1 InovAI) + PMI; ESM-2 no multimodal
4. **Validação:** LOPO é a métrica honesta; isotônica calibra o dashboard
5. **Resultado:** baseline LOPO AUC $\approx 0,88$; multimodal LOPO AUC $\approx 0,81$
6. **Uso:** priorizar candidatos Stigmurin/análogos antes do in vitro

