

PepMem-AI

Dados, modelagem e resultados

Priorização in silico de peptídeos escorpiônicos
antes da validação experimental in vitro

InovAI Lab / LANCE — IMD/UFRN

Métricas dos artefatos em `data/processed/models/` (treino commitado)

Agenda

1. Problema e pergunta do modelo
2. Dados: fontes, volume e rótulo
3. Features: clássicas, PMI e ESM-2
4. Modelagem: RF, LOPO e calibração
5. Resultados (baseline e multimodal)
6. Uso: dashboard, API e deploy
7. Limitações e próximos passos

Contexto

Peptídeos de *Tityus stigmurus* (Stigmurin e análogos) interagem com membranas diversas (Gram+/Gram-, fungo, célula mamífera). Testar todos os pares in vitro é caro.

Pergunta operacional

- ▶ Dado peptídeo + membrana-alvo,
- ▶ qual a chance de alta atividade?
- ▶ Rótulo: MIC $\leq$ 3,4 μ M

Papel do PoC

Priorizar candidatos.
Não substitui MIC,
hemólise nem clínica.

De onde veio o desenho

Pipeline InovAI (Nível 1)

Baselines: RF, XGBoost, SVM, logreg.

Com poucos dados: classificador + encoder congelado; PMI + SHAP.

PoC implementado

RF (baseline e multimodal).

ESM-2 τ_6 _8M como embedding.


SHAP TreeExplainer no dashboard.

Proposta CNPq (horizonte)

Deep learning multimodal (MLP / Transformers).

Meta de médio/longo prazo;

não é o modelo em produção no Cloud.



- ▶ Bancada **sobrescreve** literatura no mesmo par (`import_bench_mic.py`).
- ▶ Distribuição atual dos MICs: **78** bancada + **12** literature = **90**.
- ▶ Alvos com MIC: **18** membranas distintas.

Conjunto de treino

- ▶ **90** pares com MIC
- ▶ **10** peptídeos distintos
- ▶ Taxa positiva: **44,4%**

Rótulo binário

$$y = \begin{cases} 1 & \text{se } \text{MIC} \leq 3,4 \mu\text{M} \\ 0 & \text{caso contrário} \end{cases}$$

Limiar operacional do projeto
(valores ativos em Parente 2022).

Mediana dos MICs $\approx 4,7 \mu\text{M}$ — o corte $3,4 \mu\text{M}$ *não* é a mediana.

Features — baseline (11)

- ▶ Peptídeo: q , h , μH
- ▶ Membrana: carga superficial, fração aniônica, colesterol, LPS, peptidoglicano, ergosterol, envelope viral
- ▶ **PMI** (índice interpretável)

$$\text{PMI} = \alpha q_p |q_m| + \beta h_p h_m + \gamma \mu H_p - \delta \text{col}_m$$

$$\alpha=1,0, \beta=0,5, \gamma=0,3, \delta=0,4$$

Carga se não informada

Soma simplificada a $\text{pH} \sim 7$:

K,R = +1; H = +0,1;

D,E = -1.


Features — multimodal (+ ESM-2)

- ▶ Embedding: facebook/esm2_t6_8M_UR50D
- ▶ Agregação: **mean-pooling** dos resíduos → vetor $\sim$ **320** dims
- ▶ Entrada do RF: 11 clássicas + 320 $\approx$ **331** features
- ▶ Artefato: data/processed/embeddings/esm2_all.npz

Por que t6 8M?

Feito para proteínas; só precisa da sequência; cabe em CPU / HF Space; complementa o PMI sem exigir estrutura 3D.

Pipeline de modelagem



- ▶ Pipeline: `StandardScaler` → `RandomForestClassifier`
- ▶ Baseline: 200 árvores; multimodal: 300 árvores, `max_depth=6`
- ▶ `class_weight='balanced'`

Validação: LOO vs LOPO

LOO (por amostra)

Tira **1 par** por vez.

O mesmo peptídeo pode ficar no treino (outro alvo).

AUC mais otimista

(vazamento por homologia).

LOPO (por peptídeo)

Tira **todo** o peptídeo.

Generalização para sequência nunca vista.

Métrica principal +

probs OOF para calibração.

Família Stigmurin: análogos ~94% idênticos $\Rightarrow$ LOPO é essencial.

- ▶ RF ordena bem, mas `predict_proba` é **voto do ensemble**, não frequência real.
- ▶ Com ~ 90 MICs, probs brutas tendem a polarizar (0/1).
- ▶ **IsotonicRegression** nas probs OOF do LOPO $\rightarrow p_{\text{calibrada}}$.
- ▶ Preserva a ordem dos candidatos; alinha % do dashboard ao LOPO.

Inferência

$$p_{\text{bruta}} = \text{RF.predict_proba} \rightarrow p_{\text{calibrada}} = \text{calibrator.predict}([p_{\text{bruta}}])$$

Métrica	LOO	LOPO
AUC	0,878	0,878
Acurácia	0,833	0,744
F1 (classe positiva)	0,828	0,729

- ▶ Modelo: 11 features clássicas + PMI
- ▶ Deploy: Streamlit Cloud (sem PyTorch)
- ▶ Calibração: isotônica sobre OOF LOPO

Métrica	LOO	LOPO
AUC	0,845	0,809

- ▶ 331 features (clássicas + embedding)
- ▶ LOPO cai mais que o baseline: embedding captura similaridade de sequência; sem o peptídeo no treino, generaliza um pouco pior nesta família pequena
- ▶ Deploy: Hugging Face Space / local com `requirements-space.txt`

AUC LOPO por peptídeo (baseline)

ID	AUC	ID	AUC
P11	0,90	P15	0,83
P12	0,95	P16	0,95
P13	0,88	P17	0,80
P14	0,88	P18	0,67

- ▶ P05 e P10: AUC por peptídeo indefinida (uma só classe no fold)
- ▶ Variabilidade entre análogos — amostra ainda limitada

SHAP

TreeExplainer no RF.
Beeswarm global + local.
Dims ESM agregadas no gráfico.

Onde roda

Cloud: baseline leve
Space HF: multimodal
API FastAPI (opcional)

Dashboard

Predição única / lote FASTA
Ranking multi-alvo
Relatórios MD/DOCX/PDF

Docs

`docs/TREINO.md`
`docs/INTERPRETACAO_RESULTADOS.md`

- ▶ Poucos peptídeos distintos (~ 10 com MIC) — LOPO ajuda, mas amostra é pequena
- ▶ Limiar $3,4 \mu\text{M}$ é escolha de projeto, não padrão CLSI
- ▶ Hemólise existe nos pares, mas o RF classifica **atividade MIC**, não toxicidade direta
- ▶ Multimodal ainda é RF+ESM, não o encoder multimodal completo da proposta CNPq
- ▶ Predição **prioriza** ensaio; não substitui bancada

1. **Dados:** 90 MICs (bancada + literatura), rótulo $\text{MIC} \leq 3,4 \mu\text{M}$
2. **Modelo:** Random Forest (Nível 1 do pipeline InovAI) + PMI; ESM-2 no multimodal
3. **Validação:** LOPO é a métrica honesta; isotônica calibra o dashboard
4. **Resultado:** baseline LOPO AUC $\approx 0,88$; multimodal LOPO AUC $\approx 0,81$
5. **Uso:** priorizar candidatos Stigmurin/análogos antes do in vitro

Obrigado

Perguntas

Código: `github.com/gbmotta/PepMem-AI`

Artefatos: `baseline_mic_loo.json` · `multimodal_mic_loo.json`