


Pipeline de IA para Predição de Interação Peptídeo–Membrana

Bioprospecção de peptídeos escorpiônicos com validação experimental



Prof. Marcelo A. C. Fernandes
InovAI Lab | IMD/UFRN



InovAI LAB

Transformando Ideias em Realidade

Projeto de bioprospecção

O projeto busca identificar peptídeos escorpíonicos com potencial terapêutico, combinando triagem computacional, inteligência artificial e validação experimental in vitro.

Candidatos principais

- ▶ Peptídeos derivados de venenos de escorpiões.
- ▶ Análogos de Stigmurina e TsAP-2.
- ▶ Moléculas com carga, hidrofobicidade e anfipaticidade favoráveis.


Atividades de interesse

- ▶ Antibacteriana e antifúngica.
- ▶ Antiparasitária.
- ▶ Antiviral.
- ▶ Antitumoral e baixa citotoxicidade.



Desafio experimental

Testar todos os peptídeos contra todos os alvos biológicos pode ser caro, lento e pouco escalável.



- ▶ A IA prioriza os candidatos com maior chance de atividade e seletividade.
- ▶ A bancada confirma as predições e gera novos dados para melhorar o modelo.





Reinterpretação computacional

Do ponto de vista de IA, a pergunta central não é apenas se o peptídeo é ativo. A pergunta é: **como um peptídeo interage com uma membrana específica e qual efeito essa interação produz?**

- ▶ Membranas bacterianas, fúngicas, parasitárias, virais, normais e tumorais são diferentes.
- ▶ O mesmo peptídeo pode ser ativo em uma membrana e tóxico ou inativo em outra.


Pergunta central

Construir um pipeline computacional para prever se um peptídeo escorpiônico interage, permeabiliza ou desestabiliza uma membrana biológica específica.

- ▶ Formular o problema como **interação peptídeo–membrana**.
- ▶ Representar peptídeos por descritores físico-químicos e embeddings.
- ▶ Representar membranas-alvo por carga, composição, estrutura e propriedades físicas.
- ▶ Construir modelos de IA para predição, ranqueamento e seleção experimental.
- ▶ Fechar o ciclo com validação in vitro e realimentação do modelo.




- ▶ Peptídeos de venenos de escorpiões podem apresentar atividades antimicrobiana, antifúngica, antiviral, antiparasitária e antitumoral.
- ▶ Muitas dessas atividades dependem da interação com membranas biológicas.
- ▶ Características importantes dos peptídeos:
 - carga positiva;
 - hidrofobicidade;
 - anfipaticidade;
 - tendência helicoidal;
 - momento hidrofóbico.



Entrada e saída do modelo


Dado um par **peptídeo–membrana**, prever a probabilidade ou intensidade de interação funcional.



$$f(p_i, m_j) \rightarrow y_{ij}$$

- ▶ p_i : representação do peptídeo.
- ▶ m_j : representação da membrana-alvo.
- ▶ y_{ij} : atividade, permeabilização, toxicidade ou seletividade.





Ideia principal

A IA não substitui a bancada. Ela prioriza os candidatos mais promissores para reduzir custo, tempo e número de ensaios.



Fontes de peptídeos

- ▶ Peptídeos escorpiônicos do projeto.
- ▶ Peptídeos antimicrobianos de bancos públicos.
- ▶ Peptídeos penetrantes celulares.
- ▶ Artigos com MIC, IC50, CC50, EC50 ou atividade antiviral.

Fontes de membranas e alvos

- ▶ Bactérias Gram+ e Gram-.
- ▶ Fungos e leveduras.
- ▶ Parasitas.
- ▶ Vírus envelopados.
- ▶ Células normais e tumorais.

Unidade da base

Cada linha deve representar um par: **peptídeo + alvo + desfecho experimental.**



Endpoints experimentais: o que significam?

End.	Significado	Leitura no projeto	End.	Significado	Leitura no projeto
MIC	Conc. Inibitória Mínima	Menor concentração que inibe crescimento microbiano visível. Menor MIC indica maior atividade.	IC50	Conc. Inibitória 50%	Concentração que reduz proliferação ou atividade celular em 50%. Útil para células tumorais e parasitas.
MBC/ CBM	Conc. Bactericida Mínima	Menor concentração capaz de matar bactérias. Diferencia ação bactericida de bacteriostática.	CC50	Conc. Citotóxica 50%	Concentração que reduz viabilidade de células normais em 50%. Maior CC50 indica menor toxicidade.
MFC/ CFM	Conc. Fungicida Mínima	Menor concentração capaz de matar fungos ou leveduras.	EC50	Conc. Efetiva 50%	Concentração que produz 50% do efeito máximo, comum em ensaios antivirais.
			SI	Índice de Seletividade	Razão entre toxicidade e atividade, por exemplo $SI = CC50/IC50$ ou $CC50/MIC$. Maior SI é melhor.

Ideia central para a IA

Os endpoints são transformados em rótulos ou valores-alvo para treinar o modelo de interação peptídeo-membrana.



INOVA

Transformando Ideias em Realidade

peptide_id	sequence	target	target_type	endpoint	value
P01	FFSLIPSLVGGLISAFK	<i>S. aureus</i>	Gram+	MIC	8 μ M
P01	FFSLIPSLVGGLISAFK	célula normal	mamífero normal	CC50	100 μ M
P02	FLGMIPGLIGGLISAFK	<i>Candida</i> spp.	fungo	MIC	16 μ M
P03	...	Zika	vírus envelopado	redução viral	70%

- ▶ Cada linha representa um par **peptídeo + membrana-alvo + desfecho**.
- ▶ O mesmo peptídeo pode aparecer em várias linhas, uma para cada membrana-alvo.
- ▶ Isso permite aprender **seletividade**: ativo contra alvo patológico e pouco tóxico contra célula normal.




- ▶ Padronizar sequências de aminoácidos.
- ▶ Remover duplicatas e registros inconsistentes.
- ▶ Converter unidades: μM , $\mu\text{g/mL}$, nM .
- ▶ Tratar modificações: amidado, acetilado, substituições.
- ▶ Padronizar nomes de organismos e linhagens.
- ▶ Definir classes: alta, média ou baixa atividade.

Exemplo de regra

Para MIC, valores menores indicam maior atividade. Uma regra inicial pode ser:

- ▶ $\text{MIC} \leq 10 \mu\text{M}$: alta atividade.
- ▶ $10 < \text{MIC} \leq 50 \mu\text{M}$: atividade moderada.
- ▶ $\text{MIC} > 50 \mu\text{M}$: baixa atividade.

Etapa 3 - Representação do peptídeo



Representação final


$$p_i = [\text{descritores clássicos}, \text{embedding da sequência}]$$

Descritor	Interpretação biológica
Carga líquida	Interação eletrostática com membranas negativas.
Hidrofobicidade	Capacidade de inserção na bicamada lipídica.
Momento hidrofóbico	Organização anfipática, comum em peptídeos helicoidais.
Ponto isoelétrico	Comportamento de carga em função do pH.
Massa molecular	Tamanho e difusão do peptídeo.
Comprimento	Relacionado a estabilidade, poro e permeação.
Fração catiônica	Presença de Lys, Arg e His.
Fração hidrofóbica	Presença de Leu, Ile, Val, Phe, Trp etc.



Ideia

Modelos pré-treinados em grandes bases de proteínas transformam sequências em vetores densos que capturam padrões evolutivos, estruturais e funcionais.



- ▶ O embedding pode ser usado sozinho ou combinado com descritores clássicos.
- ▶ Para poucos dados, recomenda-se congelar o encoder e treinar apenas o classificador/regressor.

Ponto-chave

A membrana não deve ser apenas uma classe como “bactéria” ou “célula tumoral”. Ela deve ser descrita por propriedades físico-químicas e estruturais.

$$m_j = [T_j, C_j, A_j, L_j, S_j, R_j]$$

- ▶ T_j : tipo de membrana.
- ▶ C_j : carga superficial.
- ▶ A_j : fração aniônica.
- ▶ L_j : composição lipídica.
- ▶ S_j : componentes estruturais.
- ▶ R_j : rigidez, fluidez e espessura.



Classe	Exemplos	Uso no projeto
Gram-positiva	S. aureus, S. epidermidis	Atividade antibacteriana.
Gram-negativa	E. coli, P. aeruginosa	Atividade antibacteriana e barreira externa.
Fungo/levedura	Candida spp.	Atividade antifúngica.
Parasita	Trypanosoma cruzi	Atividade antiparasitária.
Vírus envelopado	Zika, HSV	Desestabilização de envelope viral.
Célula normal	linhagens não neoplásicas	Toxicidade indesejada.
Célula tumoral	linhagens cancerígenas	Atividade antiproliferativa.



Descritor	Importância
Carga superficial	Atrai ou repele peptídeos catiônicos.
Fração de lipídios aniônicos	Relacionada à seletividade para bactérias e células tumorais.
LPS	Característico de Gram-negativas; camada externa e carga negativa.
Peptidoglicano	Barreira estrutural em bactérias.
Ácido teicoico	Relevante em Gram-positivas.
Colesterol	Estabiliza membranas de mamíferos e pode reduzir permeabilização.
Ergosterol	Marcador importante de membranas fúngicas.
Envelope viral	Indica alvo lipídico em vírus envelopados.
Fluidez/rigidez	Controla deformação, inserção e formação de poros.
Espessura da bicamada	Afeta profundidade de inserção do peptídeo.



Alvo	Carga	Aniônica	LPS	PGN	Col.	Erg.	Env.
S. aureus	-0.80	0.60	0	1	0	0	0
E. coli	-0.90	0.65	1	1	0	0	0
Candida spp.	-0.40	0.25	0	0	0	1	0
Zika	-0.30	0.20	0	0	1	0	1
Célula normal	-0.10	0.10	0	0	1	0	0
Célula tumoral	-0.40	0.25	0	0	1	0	0

- ▶ Os valores iniciais podem ser aproximados da literatura.
- ▶ Depois, podem ser refinados com dados experimentais, lipossomos ou dinâmica molecular.

Nível 1 simples

Tipo, carga, LPS, colesterol, ergosterol e fração aniônica.

Nível 2 intermediário

Composição lipídica aproximada, fluidez, rigidez e espessura.

Nível 3 avançado

Descritores de dinâmica molecular, lipossomos, potencial zeta e energia de inserção.

rápido e
robusto

melhor
biologia


maior
mecanismo



Entrada final do modelo

$$x_{ij} = [p_i, m_j, g(p_i, m_j)]$$


- ▶ p_i : descritores e embedding do peptídeo.
- ▶ m_j : descritores da membrana.
- ▶ $g(p_i, m_j)$: atributos cruzados de interação.



- ▶ Compatibilidade eletrostática.
- ▶ Compatibilidade hidrofóbica.
- ▶ Penalização por colesterol.
- ▶ Afinidade por membranas aniônicas.
- ▶ Potencial de seletividade.

Ideia

Além de representar peptídeo e membrana separadamente, podemos criar descritores que expressem **como os dois combinam entre si**.



Objetivo do PMI

Construir um índice simples e interpretável para resumir a compatibilidade entre um peptídeo e uma membrana-alvo antes ou junto do modelo de IA.

$$PMI = \alpha Q_p |Q_m| + \beta H_p H_m + \gamma \mu H_p - \delta Chol_m$$

- ▶ Valores maiores sugerem maior potencial de interação, inserção ou perturbação da membrana.
- ▶ O PMI pode ser usado como feature adicional ou como baseline interpretável.
- ▶ Os pesos α , β , γ e δ podem ser definidos empiricamente ou aprendidos pelo modelo.



Termo	Representa	Intuição biológica
$Q_p Q_m $	compatibilidade eletrostática	Peptídeos catiônicos tendem a interagir com membranas mais negativas.
H_pH_m	compatibilidade hidrofóbica	Peptídeos hidrofóbicos podem se inserir melhor em ambientes lipídicos.
μH_p	momento hidrofóbico	Captura anfipaticidade, importante para hélices que interagem com bicamadas.
$Chol_m$	fração de colesterol	Pode estabilizar membranas de mamíferos e reduzir permeabilização por alguns peptídeos.

Leitura prática


Um peptídeo bom deve ter PMI alto para a membrana patológica e PMI baixo para a célula normal.



Problema biológico

Não basta interagir fortemente com membranas. É necessário interagir preferencialmente com o alvo patológico e pouco com células normais.

$$PMI_{sel} = PMI_{alvo\ patológico} - PMI_{célula\ normal}$$



- ▶ $PMI_{sel} > 0$: favorece alvo patológico.
- ▶ $PMI_{sel} \approx 0$: baixa seletividade prevista.
- ▶ $PMI_{sel} < 0$: risco de maior interação com célula normal.

Uso como baseline

- ▶ Calcular o PMI para todos os pares peptídeo–membrana.
- ▶ Ordenar os candidatos por PMI_{sel} .
- ▶ Comparar com resultados experimentais.


Uso como feature

- ▶ Adicionar PMI ao vetor x_{ij} .
- ▶ Permitir que RF, XGBoost ou MLP aprendam pesos melhores.
- ▶ Usar SHAP para verificar a importância do PMI.

Cuidado

O PMI é uma simplificação. Ele não substitui embeddings, composição lipídica detalhada, dinâmica molecular ou validação experimental.






- ▶ **Nível 1:** Random Forest, XGBoost, SVM e regressão logística.
- ▶ **Nível 2:** embeddings ProtBERT/ESM-2 combinados com descritores.
- ▶ **Nível 3:** encoder de peptídeo + encoder de membrana + fusão multimodal.


Motivação

O problema peptídeo–membrana combina diferentes tipos de informação: sequência, descritores físico-químicos, propriedades da membrana e endpoints experimentais.



- ▶ A sequência captura padrões de resíduos e motivos funcionais.
- ▶ Os descritores clássicos capturam propriedades conhecidas e interpretáveis.
- ▶ A membrana define o contexto biológico da interação.

Arquitetura multimodal proposta




Estratégia	Como funciona	Quando usar
Concatenação	Junta os vetores em uma única entrada	Primeira versão, simples e robusta.
Fusão com MLP	Cada modalidade passa por uma MLP antes da fusão	Quando descritores têm escalas diferentes.
Atenção cruzada	O vetor da membrana modula quais partes do peptídeo importam	Quando houver dados suficientes.
Fusão multitarefa	Um tronco comum alimenta várias saídas	Para prever atividade, toxicidade e seletividade juntas.

Recomendação inicial

Começar com concatenação + MLP, usando embeddings congelados, e evoluir para atenção cruzada quando a base crescer.





- ▶ A saída multitarefa força o modelo a aprender atividade e segurança simultaneamente.
- ▶ O ranking final pode combinar as três cabeças preditivas.



Tarefa	Saída	Exemplo
Classificação binária	Interage ou não interage	membrana-ativo / não ativo
Classificação ordinal	Baixa, média ou alta interação	classe de atividade
Regressão	Valor contínuo	MIC, IC50, CC50, EC50
Ranqueamento	Ordem dos candidatos	Top-5 peptídeos para bancada
Multitarefa	Várias saídas simultâneas	atividade, toxicidade, seletividade

Recomendação

Começar com classificação/ranking e evoluir para regressão e multitarefa quando houver mais dados.



Divisão dos dados

- ▶ Treino.
- ▶ Validação.
- ▶ Teste interno.
- ▶ Teste externo com literatura.
- ▶ Teste prospectivo com bancada.

Métricas

- ▶ Classificação: acurácia, precisão, recall, F1, ROC-AUC.
- ▶ Regressão: MAE, RMSE, R^2 .
- ▶ Ranking: top-k accuracy, enrichment factor.
- ▶ Seletividade: correlação com índice experimental.



Problema comum

Se peptídeos muito parecidos aparecem simultaneamente no treino e no teste, o desempenho pode ficar artificialmente alto.

- ▶ Fazer split por cluster de similaridade, não apenas split aleatório.
- ▶ Separar peptídeos análogos próximos.
- ▶ Usar teste externo com dados não usados na curadoria.
- ▶ Reportar desempenho por tipo de alvo: Gram+, Gram-, fungo, célula normal etc.



Critério recomendado

O melhor peptídeo não é necessariamente o mais ativo. É o que combina atividade alta contra o alvo e baixa toxicidade em célula normal.

$$Score_{final} = Score_{alvo} - \lambda \cdot Score_{tox} + \eta \cdot Score_{seletividade}$$


- ▶ $Score_{alvo}$: interação prevista com bactéria, fungo, parasita, vírus ou célula tumoral.
- ▶ $Score_{tox}$: interação prevista com célula normal.
- ▶ $Score_{seletividade}$: diferença entre alvo patológico e célula normal.



Peptídeo	Alvo	Tox.	Sel.	Score	Decisão
P04	0.91	0.18	0.73	0.88	Testar primeiro
P07	0.86	0.22	0.64	0.80	Testar
P02	0.78	0.55	0.23	0.52	Cuidado
P09	0.65	0.12	0.53	0.70	Alternativa
P03	0.93	0.89	0.04	0.30	Evitar por toxicidade

- ▶ Este ranking é um exemplo didático.
- ▶ Os valores reais viriam do modelo treinado e da validação experimental.


Etapa 9 - Validação experimental



Resultado esperado

Confirmar se o modelo preditivo realmente seleciona peptídeos com atividade e seletividade.





Aprendizado ativo

A cada rodada experimental, o modelo aprende melhor quais propriedades aumentam atividade, seletividade e segurança.



Ferramentas

- ▶ SHAP.
- ▶ Permutation importance.
- ▶ Atenção em Transformers.
- ▶ Análise de resíduos importantes.

Perguntas biológicas

- ▶ A carga positiva aumenta interação?
- ▶ Hidrofobicidade excessiva aumenta toxicidade?
- ▶ Quais resíduos favorecem seletividade?
- ▶ O modelo distingue célula normal de tumor?

Objetivo da XAI

Transformar predição em conhecimento de relação estrutura-atividade.



- ▶ Base de dados curada de peptídeos, membranas e desfechos experimentais.
- ▶ Scripts de extração de descritores físico-químicos.
- ▶ Geração de embeddings por ProtBERT, ESM-2 ou ProtT5.
- ▶ Tabela de representação de membranas-alvo.
- ▶ Modelos baseline e multimodais treinados.
- ▶ Ranking dos peptídeos do projeto.
- ▶ Relatório com métricas, análise de erro e explicabilidade.
- ▶ Pipeline reproduzível em Python, preferencialmente com notebooks e scripts versionados.

Fase	Atividade	Produto
1	Revisão de bases e coleta inicial	planilha padronizada
2	Cálculo de descritores dos peptídeos	tabela de features
3	Construção da tabela de membranas	vetor m_j para cada alvo
4	Geração de embeddings	matriz de embeddings
5	Baseline RF/XGBoost/SVM	métricas iniciais
6	Modelo multimodal	predição peptídeo–membrana
7	Ranking dos candidatos	lista priorizada para bancada
8	XAI e relatório	interpretação biológica



Python e dados

- ▶ pandas, numpy, scipy.
- ▶ scikit-learn.
- ▶ xgboost.
- ▶ pyarrow/parquet.

Deep learning e bioinformática

- ▶ PyTorch.
- ▶ Hugging Face Transformers.
- ▶ ESM / ProtBERT / ProtT5.
- ▶ Biopython.
- ▶ SHAP.

Organização

Separar o projeto em módulos: dados, features, embeddings, modelos, avaliação, explicabilidade e ranking.



Artigos
modelagem, validação e aplicação



metodologia
PepMem-AI

Datasets
dados curados e reprodutíveis



peptídeos + membranas + endpoints

Plataforma Web
predição, ranking e visualização



interface para alunos e pesquisadores

Visão estratégica

Cada entregável deve reforçar os demais: os dados alimentam os modelos, os modelos geram artigos, e a plataforma torna o pipeline utilizável e demonstrável.



Artigo metodológico

PepMem-AI: um pipeline multimodal para predição de interação peptídeo–membrana

Ideia central

- ▶ Formalizar o problema como pares peptídeo–membrana.
- ▶ Comparar descritores clássicos, embeddings e modelos multimodais.
- ▶ Avaliar classificação, regressão e ranking.

Resultados esperados

- ▶ Baselines: RF, SVM, XGBoost e MLP.
- ▶ Modelos com ProtBERT/ESM-2.
- ▶ Métricas: ROC-AUC, F1, RMSE, R^2 e top-k.
- ▶ Análise XAI dos descritores relevantes.



Artigo experimental-computacional

Validação in vitro de peptídeos priorizados por IA

- ▶ Usar o ranking do modelo para selecionar candidatos.
- ▶ Validar MIC, MBC/CBM, IC50, CC50 e atividade antiviral.
- ▶ Comparar predição versus bancada.
- ▶ Discutir seletividade contra células normais.

Artigo de interpretabilidade

Determinantes físico-químicos da interação peptídeo-membrana

- ▶ Usar SHAP e análise de importância.
- ▶ Explorar carga, hidrofobicidade e momento hidrofóbico.
- ▶ Relacionar PMI com endpoints experimentais.
- ▶ Gerar hipóteses para novos análogos.



Dataset 1: PepMem-Base

- ▶ Sequências de peptídeos escorpiônicos.
- ▶ Descritores físico-químicos.
- ▶ Embeddings ProtBERT/ESM-2.
- ▶ Origem: APD3, CAMP, UniProt e literatura.

Dataset 2: Membrane-Targets

- ▶ Representações de membranas-alvo.
- ▶ Tipo, carga, fração aniônica, colesterol, ergosterol, LPS e peptidoglicano.

Dataset 3: PepMem-Endpoints

- ▶ Pares peptídeo–membrana.
- ▶ Endpoints: MIC, MBC/CBM, IC50, CC50, EC50 e SI.
- ▶ Dados da literatura e da bancada.

Formato recomendado

CSV/Parquet + dicionário de dados + scripts de reprodução + licença + DOI em Mendeley Data, Zenodo ou Figshare.




Grupo	Campos	Finalidade
Identificação	peptide_id, sequence, target, target_type	rastrear o par peptídeo-membrana
Descritores do peptídeo	net_charge, hydrophobicity, hydrophobic_moment, pI, length	representar propriedades físico-químicas
Embeddings	esm2_vector, protbert_vector	representar a sequência em espaço vetorial
Membrana	surface_charge, anionic_fraction, cholesterol, ergosterol, LPS, PG, PE, CL	representar a membrana-alvo
Endpoint	endpoint, value, unit, assay, reference	registrar o desfecho experimental
Controle de qualidade	source, duplicate_flag, confidence, split	permitir curadoria, reprodutibilidade e treino/teste

Entregável de dados

Uma versão inicial pode conter apenas dados de literatura. A versão final deve incorporar os resultados experimentais gerados no projeto.





Objetivo da plataforma

Permitir que o usuário submeta uma sequência peptídica, escolha uma membrana-alvo e receba previsões de atividade, toxicidade, seletividade e explicabilidade.



Módulos do usuário

- ▶ Cadastro ou upload de peptídeos.
- ▶ Escolha da membrana-alvo.
- ▶ Visualização do ranking.
- ▶ Relatório com justificativa da predição.

Módulos científicos

- ▶ Cálculo de descritores.
- ▶ Geração de embeddings.
- ▶ Predição multimodal.
- ▶ XAI e PMI.


Saídas da plataforma

- ▶ Score de interação peptídeo–membrana.
- ▶ Score de toxicidade prevista.
- ▶ Índice de seletividade previsto.
- ▶ Top-k peptídeos para validação in vitro.
- ▶ Download do relatório em PDF/CSV.

Diferencial

A plataforma transforma o pipeline em uma ferramenta prática para triagem, ensino, colaboração e geração de novos experimentos.





- ▶ **Curto prazo:** dataset curado, baselines e primeira versão do ranking.
- ▶ **Médio prazo:** modelo multimodal, PMI, XAI e validação com literatura.
- ▶ **Final:** validação experimental, artigos, dataset público e protótipo web.



1. O problema central é **predição de interação peptídeo–membrana**.
2. A entrada é um par: peptídeo + membrana-alvo.
3. O peptídeo deve ser representado por descritores clássicos e embeddings.
4. A membrana deve ser representada por carga, composição, componentes estruturais e propriedades físicas.
5. O modelo deve prever atividade, toxicidade e seletividade.
6. A saída mais útil é um ranking para validação experimental.
7. Os dados da bancada devem realimentar o modelo em um ciclo de active learning.

Ideia principal


O objetivo não é apenas treinar um modelo para dizer se um peptídeo é ativo. O objetivo é aprender **por que, contra qual membrana e com que seletividade** ele pode funcionar.

Peptídeo + Membrana + IA + Bancada = Bioprospecção orientada por dados

- ▶ Lee et al. Mapping membrane activity in undiscovered peptide sequence space using machine learning. *PNAS*, 2016.
- ▶ Damiati et al. Novel machine learning application for prediction of membrane insertion potential of cell-penetrating peptides. *International Journal of Pharmaceutics*, 2019.
- ▶ de Oliveira et al. Predicting cell-penetrating peptides using machine learning algorithms and navigating in their chemical space. *Scientific Reports*, 2021.
- ▶ Tran et al. Using molecular dynamics simulations to prioritize and understand AI-generated cell penetrating peptides. *Scientific Reports*, 2021.
- ▶ Cao et al. Multi_CycGT: A Deep Learning-Based Multimodal Model for Predicting the Membrane Permeability of Cyclic Peptides. *Journal of Medicinal Chemistry*, 2024.



Obrigado!



PepMem-AI

Pipeline de IA para interação peptídeo–membrana

InovAI Lab | IMD/UFRN



InovAI LAB

Transformando Ideias em Realidade